

# 华中科技大学

管理学院管理科学与工程博士项目

考虑抱怨问题路径的网络抱怨识别方法  
&  
基于支持向量机的在线负面口碑专家识别方法

报 名 号 10\*\*\*\*\*75

姓 名 张心泽

方 向 商务智能与电子商务

指 导 教 师 蔡 \*\* 教授

报 考 教 师 鲍 \*\* 教授

## 摘 要

本人系管理学院 15 级硕士研究生,在研究生阶段一直从事基金项目、大数据实验室建设和教学助理的科研教学实践工作。在科研方面,本人学术兴趣广泛、热爱学习、善于思考,钻研精神强。在参与导师蔡\*\*教授的国家自然科学基金面上项目研究中,本人提出并实现了一种考虑抱怨问题路径的网络抱怨问题识别方法和基于支持向量机的在线负面口碑处理专家识别方法。基于其多学科交叉的知识背景,硕士学位论文选取了人工智能与会计账务处理的交叉研究选题,运用有记忆和注意力机制的循环神经网络模型实现了会计分录智能编制。其中,硕士学位论文已定稿答辩并将单独陈述,因此本文将主要展示网络抱怨问题识别方法与在线负面口碑处理专家识别方法。

处理抱怨是企业管理活动中一项常见且重要的工作。本文考虑抱怨目标短语与触发短语核心词之间的句法关系,提出一种考虑抱怨问题路径的网络抱怨问题识别方法。该方法将句法关系表示为以触发短语核心词和目标短语为核心的抱怨问题路径,通过进行基于词库的目标短语识别、基于 SVM 的触发核心词识别和基于句法分析的抱怨问题路径抽取等步骤实现在线抱怨问题识别。通过对比实验验证了方法的有效性。

针对在线负面口碑处理特点,本文提出了包含领域知识水平、情感状态和互动程度三种特征维度的专家用户识别方法以帮助企业处理在线负面口碑。该方法使用向量空间模型计算用户领域知识水平,通过情感词典计算用户情感状态,并引入互动程度特征,以此构建基于支持向量机的分类模型,实现专家识别。实验表明混合特征分类模型可以显著提高在线负面口碑处理专家识别的准确率和总体效果,验证了方法的有效性。

**关键词：** 抱怨目标,触发目标核心词,抱怨问题路径,在线负面口碑,支持向量机,专家识别

## 目 录

摘要	I
<b>1 考虑抱怨问题路径的网络抱怨问题识别方法</b>	<b>1</b>
1.1 引言 . . . . .	1
1.2 研究现状 . . . . .	1
1.3 在线抱怨问题识别 . . . . .	2
1.4 实验及结果分析 . . . . .	8
1.5 结论 . . . . .	12
<b>2 基于支持向量机的在线负面口碑处理专家识别方法</b>	<b>13</b>
2.1 引言 . . . . .	13
2.2 在线负面口碑处理专家特征 . . . . .	14
2.3 实验与分析 . . . . .	18
2.4 结语 . . . . .	20
参考文献	22
附录 个人简历	24

## 一 考虑抱怨问题路径的网络抱怨问题识别方法

### 1.1 引言

在以客户为中心的市场环境中,争取、转变和维系客户是企业市场战略的关键。处理好客户抱怨和客户服务恢复工作,对于维系良好的客户关系具有重要的作用。企业的客户抱怨与客户保留有显著关系<sup>[1]</sup>。及时发现和处理客户抱怨是企业维系客户关系、降低负面口碑的危害以及增强企业盈利能力的重要方法,对企业提高管理效率和服务质量具有重要意义。

基于 web2.0 技术的社会化媒体平台克服了只有企业才能网络上发表内容的局限,为顾客发表不满意的产品或服务体验(即在线抱怨)提供了平台。多样性的网络平台既激发了顾客发表的积极性也加速了这些网络抱怨的传播,在今天的网络上,抱怨随处可见。对企业而言,在线抱怨虽然存在造成顾客流失和企业效益损失的负面影响,但也能给企业提供产品或服务相关的有用信息,如提供辅助产品设计者进行旧产品改进和新产品设计的信息<sup>[2]</sup>,帮助企业了解顾客所关注产品或服务的问题以达到提高服务质量的目的。

### 1.2 研究现状

在文本挖掘领域中,意见挖掘是热门的研究课题,产品的特征抽取和情感极性识别是其中的两个主要研究问题<sup>[3,4]</sup>。它们关注的焦点是顾客对评论中涉及的产品特征的情感极性是正、负还是中立。虽然关于具体产品特征的情感表达语句可通过情感分类技术进行识别,但是产品设计人员和抱怨处理一线员工的信息需求仍无法得到满足。许多意见挖掘方法可以准确区分文本描述的产品特征但却不能挖掘顾客对产品表达不满或消极意见的具体原因。

针对此类问题,Solovyev 和 Ivanov<sup>[5]</sup>提出基于词典的问题提取方法,该方法采用模式匹配的方式实现问题的提取。鉴于此,Gupta<sup>[6]</sup>、Ivanov 和 Tutubalina<sup>[7]</sup>与通过构建问题识别规则并基于规则进行问题抽取,这样可在一定程度上提高准确性。然而问题识别规则的构建需要较强的专家知识,且规则规模小会导致准确率的降低,规则规模大则会增加其构建成本。为了在减少成本的同时提高准确率,Kurihara 和 Shimada<sup>[8]</sup>提出了一个基于 bootstrapping 的 twitter 问题信息抽取方法,该方法根据日语的特定动词、动词与否

定词组成的语法结构特征获取问题的表达。De Saeger<sup>[9]</sup>, Tutubalina 和 Elena<sup>[10,11]</sup> 将抱怨问题结构化为目标短语和触发短语的二元组, 其中目标短语表示领域依存客体(即抱怨产品及特征); 触发短语是抱怨产品及其特征的问题状态描述, 从而将抱怨问题的抽取转化为目标短语和触发短语的抽取。它们首先基于触发短语词库识别触发短语, 再根据触发短语和目标短语之间的语法特征、语义特征及相互关系确定目标短语, 最后组合触发短语和目标短语, 实现抱怨问题的自动识别。De Saeger 等、Tutubalina 和 Elena 的方法避免了问题识别规则的构建, 进一步提供了问题识别的准确性。然而, 这些方法忽略了触发短语和目标短语之间的句法关系, 无法确定抽取出的触发短语与目标短语组合可以正确表示该语句表示的抱怨, 所以他们的方法不可避免地会对问题识别准确性造成影响。

针对此问题, 本文将触发短语定义为触发短语核心词与相应修饰词的组合, 将句法关系表示为以触发短语和目标短语为核心的抱怨问题路径, 研究考虑抱怨问题路径的在线抱怨问题识别方法, 其主要功能包括基于目标短语库的目标短语识别、基于 SVM 的触发核心词识别和基于组成结构和依存结构的抱怨问题路径抽取。

## 1.3 在线抱怨问题识别

### 1.3.1 在线抱怨问题表示结构

抱怨问题是抱怨内容反映的产品或服务存在问题的抽象表示, 它主要由抱怨目标、触发短语(触发核心词与相应修饰词)及抱怨问题路径组成:

(1) 抱怨目标短语 *Target(Tar)*。作为抱怨目标, 抱怨产品或服务及其特征是抱怨问题中抱怨情绪指向的对象, 它是抱怨问题不可或缺的部分。本文将抱怨产品或服务及其特征定义为抱怨目标短语。如“根本就无法接受短信”中“短信”就是抱怨目标短语。

(2) 触发短语 *Problem-Word(PW)*。考虑到描述抱怨产品及其特征的问题状态的触发短语缺乏固定模式, 触发短语的核心词(即描述目标短语问题状态的触发短语的核心词)被定义为触发核心词 *Trigger(Tri)*, 触发核心词及其词修饰该核心词的组合被定义为触发短语。如“无法接受”是触发短语, “接受”是触发核心词, “无法”是触发核心词的相应修饰词。

(3) 抱怨问题路径 *Path*。抱怨目标短语和不考虑修饰词的抱怨核心词的简单组合可形成抱怨问题, 但这样的简单组合忽略了两者的句法关系(即 De Saeger、Tutubalina 等人的做法)。本文将{(触发核心词, 相应修饰词), 抱怨目标短语}这样的句法关系定义并表示为抱怨问题路径。

根据如上描述, 抱怨问题的识别可分解为抱怨目标短语的识别、触发核心词的识别及抱怨问题路径的抽取。基于此, 本文通过引入组成结构分析、依存结构分析和统计学习技术, 设计出如图 1-1 所示的识别方法框架。

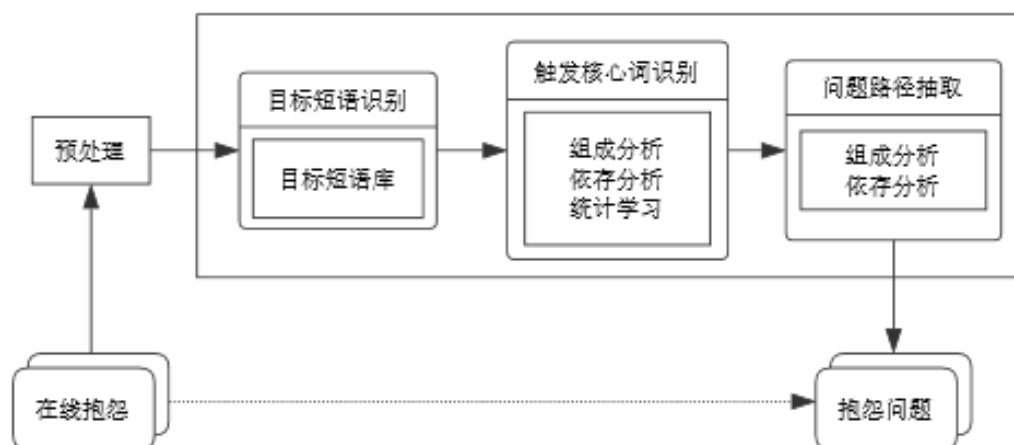


图 1-1 在线抱怨问题识别框架

### 1.3.2 抱怨目标短语识别

作为抱怨识别的一个重要组成部分, 抱怨目标短语识别是后续触发核心词识别和抱怨问题路径抽取的基础。通常情况下, 抱怨目标短语指的是在线抱怨涉及的产品或服务及特征, 其中产品特征又分为显性产品特征和隐性产品特征。显性产品特征即直接出现在产品句子中的产品特征, 如“这里信号好差”中的“信号”即为显性产品特征; 隐性产品特征即没有直接出现在句子里、以其他词语描述的间接方式出现的产品特征, 如“啥都没干就用了 100M”中的“100M”所描述的手机流量即为隐性产品特征。

在意见挖掘领域, 众多学者(如 Kurihara 和 Shimada<sup>[8]</sup>、Liu 等<sup>[12]</sup> 和 Lee 等<sup>[13]</sup>) 为产品特征识别提出了很多不同的方法, 这些方法有效地实现了产品特征的自动抽取, 然而它们需要大量难以直接获得的标记数据, 且较难直接应用于其他领域。本文通过搜索领域常用产品及其特征描述的词汇构建抱怨目标短语库, 并根据是否与所建短语库匹配的方式完成抱怨目标短语的识别。

### 1.3.3 触发核心词识别

作为抱怨问题识别的关键, 触发核心词的识别在抱怨问题识别中具有承上启下的作用, 一则因为触发核心词的存在与抱怨目标相对应, 二则触发核心词及相应修饰词是抱怨问题路径抽取的基础。

在触发核心词识别过程中, 如何确保抱怨目标短语与所识别的触发核心词相对应是

一个不可回避的问题。为解决这一问题,先将在线抱怨内容分句,进行组成结构分析,以确保抱怨目标短语和触发核心词在同一个句子中;接着,在进行句法依存分析时,只将句子中与抱怨目标短语存在依存关系的词语作为候选触发核心词,其他词语不予考虑。在进行这样的预处理后,可作如下假设:

**假设 1.1.** 抱怨目标短语和触发核心词在同一个句子中。

**假设 1.2.** 在句法分析中,触发核心词必须与抱怨目标短语存在依存关系。

基于上述假设,可将与抱怨目标短语在同一个句子且存在依存关系的词语确定为候选触发核心词,再将触发核心词的识别转化为一个二分类问题,并训练一个有监督的高斯核支持向量机(SVM)分类器进行分类。SVM 分类器通过学习触发核心词的特征,以判定候选触发核心词是否为既定抱怨目标短语对应的触发核心词,从而完成触发核心词的识别。

SVM 是 Vapnik 等<sup>[14]</sup> 在统计学习理论上提出的有监督的机器学习模型,它被广泛应用于分类、回归分析及模式识别。对于二分类, SVM 主要通过核函数把原始空间数据向高维特征空间映射,以解决低维空间中线性不可分的问题。具体地,设  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$  为训练数据集,其中  $x_i \in X = \mathbb{R}^N$ ,  $y_i \in Y = \{-1, 1\} (i = 1, 2, \dots, N)$ 。若存在向量  $w_i$  和标量  $b$ , 满足 Mercer 定理的半正定高斯核函数  $K$ :

$$K(x_i, y_i) = \exp\left(-\frac{\|x_i - y_i\|}{2\delta^2}\right) \quad (1.1)$$

且通过  $K$  的数据  $x_i$  从原始输入空间  $X$  到高维特征空间  $F$  的映射  $\phi(x_i)$  满足:

$$\begin{cases} w_i^T \cdot \phi(x_i) + b \geq 0, & y_i = 1 \\ w_i^T \cdot \phi(x_i) + b < 0, & y_i = -1 \end{cases} \quad (1.2)$$

且将分类函数  $f(x)$  定义为:

$$f(x_i) = W_i^T \cdot \phi(x_i) + b \quad (1.3)$$

通过引入松弛变量  $\xi_i$  和惩罚参数  $C$ , SVM 的最大间隔分类函数可表示为:

$$\max \frac{2}{(\|w\| + 2C \sum_{i=1}^N \xi_i)} \quad (1.4)$$

其中  $\xi_i \geq 0$  且  $y_i(w_i^T \cdot \phi(x_i) + b) \geq 1 - \xi_i$ 。

引入拉格朗日乘子  $C \geq \alpha_i \geq 0, i = 1, 2, 3, \dots, n$ , 根据 Karush-Kuhn-Tucke 条件, 将求解公式 1.4 最大间隔问题转化为使目标函数  $L(\alpha_i)$  最大问题:

$$\begin{cases} \sum_{i=1}^n \alpha_i y_i = 0, \alpha_i \geq 0 \\ \max_{\alpha} L(\alpha_i) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(x_i), \phi(x_j) \rangle \end{cases} \quad (1.5)$$

最后, 通过序列最小最优化 SMO 算法对拉格朗日乘子  $\alpha_i$  求解, 可解出  $w_i^T$  和  $b$ :

$$\begin{cases} w_i = \sum_{i=1}^n \alpha_i y_i \phi(x_i) \\ b = -\frac{\max_{i: y_i=-1} (w_i^T \cdot \phi(x_i)) + \min_{i: y_i=1} (w_i^T \cdot \phi(x_i))}{2} \end{cases} \quad (1.6)$$

根据解出的  $w_i$  和  $b$  可确定基于训练集  $T$  的分类函数  $f(x)$ , 并将其用于测试数据的分类。

对于 SVM 分类特征, 可通过包括组成结构分析和依存结构分析在内的句法分析和统计分析获取, 获取后的词语特征如表 1.1 所示。

表 1.1 词语特征

特征类型	特征描述
位置特征 $L$	是否是第一个词; 是否是最后一个词; 在句子中的现有位置; 与抱怨目标的位置距离
语法特征 $Syn$	词性; 是否是定词; 是否是负面词; 是否与否定词存在依存关系; 是否与负面词存在依存关系; 是否与把被让存在依存关系; 与抱怨目标依存关系
位置特征 $Sta$	与抱怨目标的共现次数; 在候选触发核心词库中出现的次数

基于如上叙述, 可设计如算法 1.1 的触发核心词识别算法:

在算法 1.1 的句子依存结构树  $DT = \{DP, DR\}$  中,  $DP$  为  $DT$  的节点集合  $\{dp_i\} (i = 1, 2, \dots, M; dp_m \in Tar; dp_n \in Tri; 1 \leq m, n \leq M)$ ,  $DR$  为节点间的依存关系集合  $\{dr(dp_i, dp_k)\} (i, k = 1, 2, \dots, N)$ ; 在组成结构树  $CT = \{CP, CR\}$  中,  $CP$  为组成结构树的节点集合  $\{cp_j\} (j = 1, 2, \dots, A; cp_a \in Tar; dp_b \in Tri; 1 \leq a, b \leq A)$ ,  $CR$  为节点间的依存关系集合  $\{cr(cp_j, cp_s)\} (j, s = 1, 2, \dots, B)$ , 候选触发核心词集  $CW = \{dp_p\} (p = 1, 2, \dots, P)$ ; 在触发核心词训练集  $TrainS$  中,  $trains_{L_p}$ 、 $trains_{Syn_p}$ 、 $trains_{Sta_p}$  和  $R_{(Tar, dp_p)}$  分别为训练集触发核心词  $dp_p$  的位置特征、语法特征、统计特征及类别标签; 在触发核心



---

**算法 1.1:** 触发核心词识别算法

---

**Data:** 抱怨目标短语  $Tar$ :

句子的依存结构树  $DT = \{DP, DR\}$ ; 句子的组成结构树  $CT = \{CP, CR\}$ ;

触发核心词训练集  $TrainS = \{trains_{L_p}; trains_{Syn_p}; trains_{Sta_p}; R_{(Tar, dp_p)}\} (p = 1, 2, \dots, P; R_{(Tar, dp_p)} = -1, 1)$ ; 触发核心词测试集

$TestS = \{tests_{L_q}; tests_{Syn_q}; tests_{Sta_q}\} (q = 1, 2, \dots, Q; R_{(Tar, dp_q)} = -1, 1)$

**Result:** 与抱怨目标  $Tar$  对应的触发核心词  $Tri$

```

1 begin
2   for  $dp_i$  in  $DP$  do
3     if  $((dr(dp_i, Tar) \in DR) \parallel (dr(Tar, d_i) \in DR))$  then
4       append  $dp_i$  to  $CW$  ;
5     end
6   end
7   for  $dp_p$  in  $CW$  do
8     append  $\{trains_{L_p}; trains_{Syn_p}; trains_{Sta_p}; R_{(Tar, dp_p)}\}$  to  $Trains$  from  $dp_p$  ;
9   end
10  random select  $trains_q$  in  $TrainS$ ;
11  trains SVM ;
12 end

```

---

词测试集  $TestS$  中,  $tests_{L_q}$ 、 $tests_{Syn_q}$  和  $tests_{Sta_q}$  分别为测试集触发核心词  $dp_q$  的位置特征、语法特征、统计特征及类别标签;

算法 1.1 的功能为既定抱怨目标短语识别对应的触发核心词, 它以句子的依存结构、组成结构、抱怨目标短语  $Tar$ 、触发核心词训练集和测试集 (输入时为空集, 在中间过程附加数据) 为输入, 以与抱怨目标短语对应的触发核心词为输出。首先, 通过判断与给定的抱怨目标短语是否在同一语句且存在依存关系, 为该抱怨目标短语确定候选触发核心词; 其次, 通过组成结构分析、依存结构分析和统计分析获取触发核心词的位置特征、语法特征和统计特征; 再次, 将候选触发核心词集汇集为训练集和测试集; 最后, 使用训练得到的 SVM 分类器对候选触发核心词进行分类, 若  $R_{(Tar, dp_q)} = 1$ , 则确定  $dp_q$  为与抱怨目标短语对应的触发核心词  $Tri$ , 此时抱怨问题被识别为以该触发核心词为核心的抱怨

问题路径。

### 1.3.4 抱怨问题路径抽取

为抱怨的核心,抱怨问题通常采用否定或负面词汇来描述抱怨目标短语的问题状况。因此,如果抱怨目标短语存在问题状况,那么触发核心词要么是否定或负面词,要么存在否定或负面词修饰触发核心词。相应地,如果触发核心词是否定或负面词,或者存在否定或负面词修饰触发核心词(即存在特定的依存关系),那么其所对应的抱怨目标短语极有可能存在问题状况。另外,为了提高抱怨问题抽取的准确性,本文对双重否定的情况进行了过滤,如果触发核心词是否定或负面词,且存在否定或负面词修饰该触发核心词,那么抱怨目标短语不存在问题状况。鉴于此,做出如下假设:

**假设 1.3.** 若触发核心词是否定或负面词,且不存在否定或负面词修饰该触发核心词,则抱怨目标短语存在问题状况。

**假设 1.4.** 若触发核心词是非否定或负面词,但与否定词或负面词存在特定的依存关系,则抱怨目标短语存在问题状况。

**假设 1.5.** 若触发核心词是否定或负面词,且与否定或负面词存在特定的依存关系,则抱怨目标短语不存在问题状况。

在确定抱怨目标短语是否存在问题状况后,如何抽取抱怨问题是接下来的工作。当触发核心词属于否定或负面词,且不存在否定或负面词修饰该核心词时,此时的触发核心词就是 Gupta<sup>[6]</sup> 定义的触发短语;当触发核心词属于非否定或负面词,但与否定或负面词存在特定依存关系时,触发核心词和相应否定或负面修饰词的组合就是触发短语。

鉴于此,本节将抱怨问题表示为由抱怨目标短语、触发核心词或及触发核心词的相应否定或负面修饰词组成的子树 **Sub-tree**,从而较好地考虑了三者间的句法关系。通过判定是否存在与触发核心词存在特定依存关系的否定或负面词以及判定触发核心词是否本身是否定或负面词,可归纳出如图 1-2所示的抱怨问题路径抽取流程。

例如,“这里信号好差”中的抱怨目标短语“信号”对应的触发核心词“差”为负面词且无对应否定或负面修饰词,因此采用由“信号”和“差”组成的 **Sub-tree** 来表示抱怨问题;“根本无法接受短信”中的抱怨目标短语“短信”对应的触发核心词“接受”为非负面或否定词但存在否定词“无法”对其修饰,因此采用由“短信”、“接受”和“无法”组成的 **Sub-tree** 来表示抱怨问题。

为了更好的表述抱怨问题路径 **Path** 的生成过程,这里以在线抱怨“这里根本收不了短信!”为例详细阐述。应用本章的抱怨目标短语识别方法和触发核心词识别方法,可识

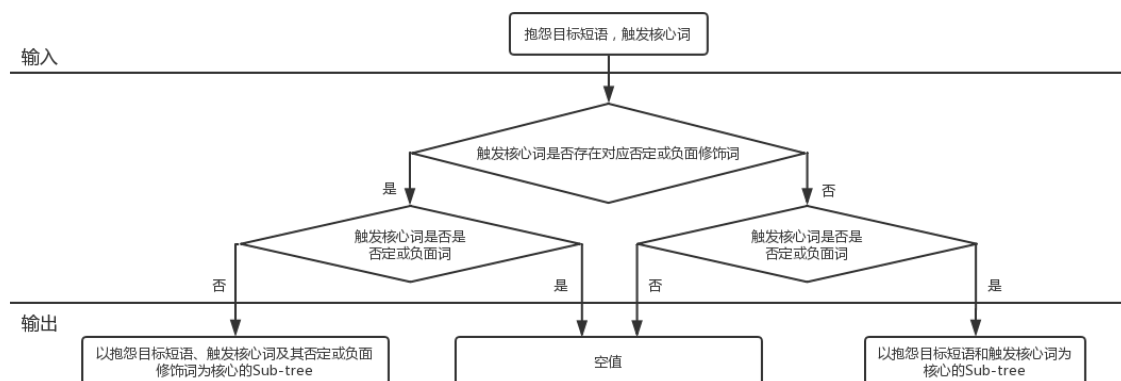


图 1-2 抱怨问题路径抽取流程

别出本例的抱怨目标短语和触发核心词,分别为“短信”和“收”,该例的抱怨问题路径抽取过程见图 1-3。

(1) 通过 Stanford Parser 句法分析工具,获取如图 1-3(a) 和图 1-3(b) 所示的句子依存结构树 (CT) 和句法组成结构树 (DT),并获取如图 1-3(c) 所示的抱怨目标短语“短信”和触发核心词“收”的最短路径 SP;

(2) 根据图 1-2 的流程进行判定,可得出抱怨目标短语“短信”和触发核心词“收”外,DP 中与触发核心词“收”存在特定依存关系的有“这里”、“不”、“了”,其中只有“不”属于否定词;

(3) 查找负面和否定词词库,得知触发核心词“收”即非负面也非否定词,故将从“不”到 SP 根节点“VP”的路径合并到 SP 中,再根据组成结构树 CT 可知抱怨问题路径的结构子树 Sub-tree;

(4) 返回抱怨问题路径抽取结果“收不了短信”。

## 1.4 实验及结果分析

### 1.4.1 数据收集和预处理

为了测试抱怨问题识别方法的准确性,本文从新浪微博随机选取了 281 条与中国移动相关的抱怨微博作为实验数据。由于这些数据存在相当多的噪声,在使用前需要进行一定的预处理,以消除不必要的干扰。预处理的过程如下:

(1) 去除散列标签。抱怨微博文本中存在很多散列标签(如 URL、“#”、“@”),它们又是作为句子的一部分存在,而又是只作为引用标签,本步骤从抱怨微博文本中通过正则匹配去除无意义的散列标签,留存那些作为句子成分和陈述了抱怨问题的标签;

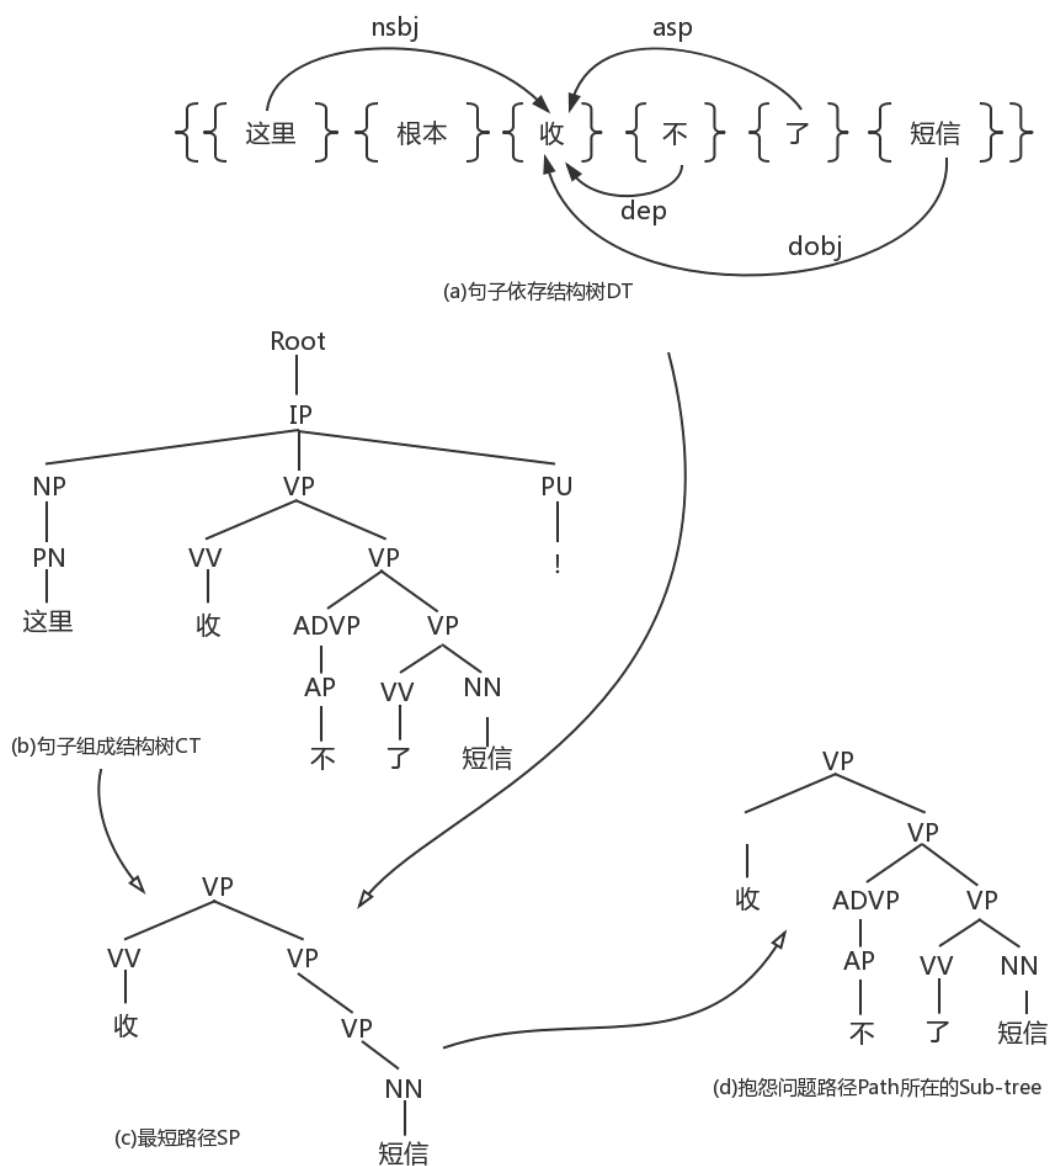


图 1-3 抱怨问题抽取过程

(2) 还原简写。由于微博具有自由编辑的特性,微博用户在发表微博抱怨时可能使用简写,如“移动”和“中移动”都是“中国移动”的简写。尽管人们可以很轻易地分析和理解这些简写,但是实现自动地分析和理解它们不在本文讨论范畴。为处理这些简写,本步骤通过人工构建简写还原词库,在避免歧义句的基础上(如“从中移动开”),将它们还原为“中国移动”;

(3) 去除重复符号和表情符号。为了实现多样化的表达,用户可以使用重复符号和表情符号(如“::>\_<::”)来表达特定的情绪。由于本文主要通过语义和语法结构分析进行抱

怨识别研究,不涉及抱怨微博所需的情感信息,不需要对重复符号和表情进行分析,故在此去除重复符号和表情符号;

(4)分句分词。考虑到抱怨微博文本通常由多个句子组成,为了保证句子组成分析和依存分析的准确性,实验对抱怨微博文本进行了分句和分词处理。

在完成了必要的预处理后,实现从 281 条抱怨微博中获取到了 756 个句子,其中 318 个句子包括至少一个抱怨问题,而 438 个句子没有包含抱怨问题,具体的实验数据统计情况如表 3 所示。

表 1.2 实验数据统计

实验数据	数量
微博数量	281
句子数目	756
微博句子平均数	2.69
不存在抱怨问题的句子数目	438
存在抱怨问题的句子数目	318
问题句子涉及抱怨目标短语数目	735
问题句子设计候选触发核心词数目	1363

实验以 318 个至少包含一个抱怨问题的句子为输入,通过完成触发目标短语识别、触发核心词识别和抱怨问题路径的抽取三个任务实现抱怨问题的识别。在触发核心词识别实验中,实验通过句法分析从 318 个句子中获取 1363 个与抱怨目标短语存在依存关系的词语,其中 249 个句子中的 1040 个词语作为训练集,69 个句子中的 323 个词语作为测试集。为评价算法 1.1,实验基于现有的知识库信息和专家意见,采用内容编码的方式对实验数据进行了触发核心词和抱怨问题的标注。

#### 1.4.2 实验设计和评价指标

实验将触发核心词的识别问题转化为分类问题,并选用 LibSVM 包完成分类任务。在进行抱怨问题路径抽取和触发核心词识别实验之前,先构建描述抱怨产品及特征的词库,并基于该词库进行抱怨目标短语识别。

实验中,负面和否定词词库一部分是根据 HowNet 提供的 3116 个中文负面情感词语和 1254 个负面评价词语构建,另一部分是通过收集如“不”、“没”等常用否定词构建;

此外,根据移动通信行业特征对词库进行了扩充,增加了如“慢”、“断”、“篡改”和“偷偷”之类的词语。

在抱怨问题的抽取中,句法分析以识别的抱怨目标短语及其对应触发核心词为核心,获取满足特定条件的抱怨目标短语和触发核心词所在的组成分析树,以实现抱怨问题的抽取。

在触发核心词识别实验中,先通过 **Standard Parser** 进行句法分析,获取与抱怨目标短语存在依存关系的词语,将这些词作为候选触发核心词,再根据句法分析、否定和负面词库获取核心词的位置特征( $Tri_L$ )、语法特征( $Tri_{Syn}$ )和统计特征( $Tri_{Sta}$ ),实验通过这三类特征的 7 种不同组合  $Tri_L$ 、 $Tri_{Syn}$ 、 $Tri_{Sta}$ 、 $Tri_{L\&Syn}$ 、 $Tri_{L\&Sta}$ 、 $Tri_{Syn\&Sta}$  和  $Tri_{L\&Syn\&Sta}$  实现触发核心词的分类,并通过结果分析选取效果最好的组合。

关于评价指标,实验采用标准机器学习分类评价指标(准确率、精确率、召回率和  $F_1$  值)<sup>[14]</sup> 对抱怨问题的抽取和触发核心词的识别进行评价。准确率  $A$  是对总体识别效果进行评价,通过识别结果中正确识别的个体与所有个体的比值来计算;精确率  $P$  表示识别方法(识别触发核心词和抱怨问题)的精确性,它通过正确识别为某类别的个体数量  $TP$  与被识别为该类别的个体总数的比值来计算;召回率  $R$  表示识别方法的完整性,它通过正确识别为某类别的个体数量  $TP$  与该类别下个体总数的比值来计算; $F_1$  值是精确率和召回率的调和平均值。各评价指标的具体公式如下:

$$A = (TP + TN) / (TP + TN + FP + FN) \quad (1.7)$$

$$P = TP / (TP + FP) \quad (1.8)$$

$$R = TP / (TP + FN) \quad (1.9)$$

$$F_1 = (2PR) / (P + R) \quad (1.10)$$

本实验中, $TP$  表示正确识别出的触发核心词总数; $TN$  表示正确识别出的非触发核心词总数; $FP$  表示不能构成触发核心词却被识别为触发核心词的总数; $FN$  表示可以构成触发核心词却被识别为非触发核心词的总数。

### 1.4.3 实验结果和分析

根据上述实验设计和评价指标设定,触发核心词识别实验的结果如表 1.3 所示。

由表 1.3 可知,在触发核心词的识别实验中只考虑语法特征的触发核心词  $Tri_{Syn}$  分类模型效果最佳,这说明了模型  $Tri_{Syn}$  在触发核心词识别中具有明显优势。在单类特

表 1.3 触发核心词识别实验结果及对比

算法	$Tri_L$	$Tri_{Syn}$	$Tri_{Sta}$	$Tri_{L\&Syn}$	$Tri_{L\&Sta}$	$Tri_{Syn\&Sta}$	$Tri_{L\&Syn\&Sta}$
准确率	0.7492	0.8824	0.7802	0.8142	0.7957	0.7956	0.8111
精确率	0	0.8644	0.6190	0.7839	0.7143	0.6667	0.7500
召回率	0	0.6296	0.3210	0.3580	0.3086	0.3704	0.3704
$F_1$	0	0.7286	0.4228	0.4915	0.4130	0.4762	0.4959

征模型中,  $Tri_{Syn}$  效果最佳,  $Tri_{Sta}$  次之,  $Tri_L$  最差; 在多类特征模型中, 考虑位置特征、语法特征和统计特征的  $Tri_{L\&Syn\&Sta}$  的效果最佳, 但与  $Tri_{L\&Syn}$ 、 $Tri_{L\&Sta}$ 、 $Tri_{Syn\&Sta}$  的效果相差不大, 且四个多类模型的触发核心词识别效果皆优于单类特征模型  $Tri_L$  和  $Tri_{Syn}$  但皆劣于  $Tri_{Syn}$ , 这说明语法特征能够显著提高触发核心词的识别效果, 尽管位置特征和统计特征也可以用于触发核心词的识别, 但其效果明显低于语法特征。基于上述触发核心词识别实验结果对比, 实验采用效率最高的模型  $Tri_{Syn}$  进行触发核心词的识别, 并基于抱怨目标短语和识别的触发核心词进行抱怨问题路径抽取, 进而完成对抱怨问题的识别。

综上所述, 本文进行的实验有如下发现: 语法特征对提高抱怨问题触发核心词识别的准确性具有显著作用; 抱怨目标短语和抱怨问题触发核心词的简单组合不能很好地表示抱怨问题, 考虑两者的句法关系可以提高抱怨问题识别的准确性。

## 1.5 结论

本文提出了一种考虑抱怨问题路径的在线抱怨问题识别方法, 该方法采用抱怨问题路径的方式表示抱怨目标短语和触发短语核心词之间的句法关系, 先后通过识别抱怨目标短语、识别触发核心词和抽取抱怨问题路径, 实现在线抱怨问题的自动识别。为测试方法的准确性和有效性, 本文进行了对比实验, 实验结果表明考虑抱怨目标短语和触发核心词间的句法关系可以提高抱怨问题识别的准确性。

在接下来的研究中, 将增加实验数据的多样性, 以提高所提方法的泛化能力; 另外, 方法中触发核心词的识别与抱怨问题的抽取均基于句法分析, 由于中文的复杂性, 错误的句法分析会直接影响到方法的准确性, 因此研究提高中文句法分析的效果也是未来工作之一。

## 二 基于支持向量机的在线负面口碑处理专家识别方法

### 2.1 引言

社会化媒体平台已成为企业客户发表和传播在线负面口碑的主要渠道,数量庞大、分布广泛的在线负面口碑给企业运营和管理带来了极大的挑战。若不能有效处理在线负面口碑使其负面影响降到最低,不仅会给企业业务带来压力,而且会对企业声誉产生不可逆转的消极影响,造成巨大损失。如 2017 年 4 月,美联航因机票超售通知航警将一位 69 岁的华裔医生暴力带离航班,事件被同机旅客拍下并上传至网络,引起大范围讨论,次周周二美联航股价一度跌超 4%,成为标准普尔 500 指数中表现最差的股票<sup>[15]</sup>。

消费者抱怨行为是用户在购买企业产品或服务过程中感知不满意引发的一系列行动。其采取的行动包括通过企业官网、客户电话等直接向企业投诉、向第三方机构申诉和通过社会化媒体平台(如新浪微博、在线论坛等)发布或转发抱怨等。在线负面口碑作为大量发布或被传播的抱怨行为已成为企业客户关系管理中的重要问题<sup>[16]</sup>。社会化媒体平台的匿名性使得发布或传播负面口碑的用户一定程度地避免遭受社会后果或报复<sup>[17]</sup>。这一特性使用户更愿意通过社会化媒体平台分享他们的负面体验。相比传统的负面口碑,在线负面口碑会对消费者行为产生更加强烈的影响,因此有效处理在线负面口碑对于企业具有重要的现实意义。

目前,企业大多采取人工客服的方式进行负面口碑的处理。这种方式不仅成本高效率低,而且很多时候并不能很好的解决用户的抱怨问题进而无法有效处理负面口碑。甚至企业这种主动干预、过度参与负面口碑处理的行为可能被用户怀疑而丧失自身公信力<sup>[18]</sup>,加深用户的厌恶感,导致更为强烈的在线负面口碑产生与扩散,造成企业的二次损失<sup>[19]</sup>。同时由于抱怨问题的海量产生与在线负面口碑的迅速扩散,仅依靠传统的人工客服已不能及时且有效地应对在线负面口碑。有效处理在线负面口碑已成为企业管理领域的热门研究课题。

Noble 等<sup>[20]</sup>提出企业应建立虚拟社区并主动对接用户,监管和处理在线负面口碑。然而社区普通用户通常不愿直接和企业沟通,更愿在虚拟社区与其他用户交流或选择在社会化媒体平台上提出抱怨问题,进而发布和传播在线负面口碑。诸多企业以开设在线客服和官方论坛的形式,将客服平台迁移至社区和平台中,并寻求辅助处理系统帮助



解决这一问题。基于此背景,袁乾<sup>[21]</sup>采用影响力衰减函数描述负面口碑的多变趋势,提出了一种基于回归树与衰减函数的 IMM-RTDF 模型来预测在线负面口碑的影响力,为企业配置在线负面口碑处理资源提供决策支持。即便如此,面对社会化媒体平台上海量发布和迅速传播的在线负面口碑,一线处理员工仍应接不暇。与此同时,社会化媒体发展过程中的一种现象值得关注。社会化媒体为用户提供了知识共享的平台,用户可在其中搜索、发布和回应信息,与其他用户形成如关注、被关注等各种虚拟社会关系,并基于社会交换的目的与他人分享和交流知识,获得一定的满足感。随着用户数量、累计发布内容和互动的增多,少量具有更多知识的用户逐渐凸显,成为社区平台上的专家用户。Cheng<sup>[22]</sup>研究表明社区平台上绝大部分有价值的解答来源于这些少量的专家用户。因此,若能识别出这些专家用户,并给予适当引导,企业可在扩展专家资源的同时,借助专家用户专业知识程度高、互动用户范围广,更易被普通用户接受的优势显著提高服务补救质量,有效处理在线负面口碑。

## 2.2 在线负面口碑处理专家特征

### 2.2.1 领域知识水平

社会化媒体平台上的专家用户传统上指代在某一领域具有一定程度的专业知识,并对该领域的抱怨问题具有较多数量或较高质量的回答。这种描述可被归纳为用户的领域知识水平(Domain Knowledge Level),即用户提供某一领域知识层面解决问题的能力。专家用户应当首先具备一定的领域知识水平才能满足抱怨问题提出者和在线负面口碑传播者对解决方案的需求。为衡量领域内用户知识水平,本文将用户在该领域内的单条回答记录视作单个文本,将用户的回答记录集合汇总为用户知识文档(user knowledge document)。通过聚集平台上所有非重复的被采纳或标记有用回答,构建该平台的领域知识文档(domain knowledge document),用来代表平台内的领域整体知识。

本文通过向量空间模型计算用户知识文档与领域知识文档的相似度,得出每个用户的领域知识水平。该模型将文档视作若干词的组合,将单个词视作一个空间维度,该词的权重制视作其有向值,由此将文档结构化为由若干词和各词权重值组成的词空间,两个文档的相似度视为词空间的相似度。具体地,设文档集  $D = \{d_1, d_2, \dots, d_N\}$ , 文档  $d_i \in D, i = (1, 2, \dots, N)$ , 可用  $d_i = \{(t_{i,1}, w_{i,1}), (t_{i,2}, w_{i,2}), \dots, (t_{i,N}, w_{i,N})\}$  表示, 其中  $t_{i,j}$  为文档  $d_i$  中的第  $j$  个词  $w_{i,j}$ , 为词  $t_{i,j}$  在文档  $d_i$  中的权重值,  $j = (1, 2, \dots, N)$ 。本文采用

TF-IDF 方法计算词的权重值  $w_{i,j}$ , 表示为:

$$\begin{aligned} w_{i,j} &= tf_{i,j} \times idf_j \\ &= \frac{num_{i,j}}{\sum_{j=1}^N num_{i,j}} \times \ln \frac{|D|}{|\{i: t_{i,j} \in d_i\}|} \end{aligned} \quad (2.1)$$

其中  $tf_{i,j}$  为词  $t_{i,j}$  在文档  $d_i$  中出现的频率, 表示为该词在文档  $d_i$  中出现的次数  $num_{i,j}$  与文档  $d_i$  中所有词出现次数之和的商;  $idf_j$  为词  $t_{i,j}$  的逆向文件频率, 表示为文档集  $D$  内的文件总数  $|D|$  与包含该词之文件数  $|\{i: t_{i,j} \in d_i\}|$  商的对数。

根据公式 2.1 可知文档内词  $t_{i,j}$  的权重值  $w_{i,j}$ , 由此可计算用户知识文档与领域知识文档的相似度, 即本文所定义用户的领域知识水平  $DKL$ , 表示为:

$$DKL_i = Sim_{(ukd_i, dkd)} = \frac{\sum_{j=1}^N w_{ukd_i,j} w_{dkd_j}}{\sqrt{\sum_{j=1}^N w_{ukd_i,j}^2} \sqrt{\sum_{j=1}^N w_{dkd_j}^2}} \quad (2.2)$$

其中  $Sim_{(ukd_i, dkd)}$  表示用户知识文档  $ukd_i$  与领域知识文档  $dkd$  的相似度,  $w_{ukd_i,j}$  为用户知识文档  $ukd_i$  中第  $j$  个词的权重值,  $w_{dkd_j}$  为领域知识文档中第  $j$  个词的权重值,  $j = (1, 2, \dots, N)$ 。

## 2.2.2 情感状态

在线负面口碑中包含了发布和传播者的负面情绪, 专家用户在满足其知识需求的同时, 应当具有抚慰其情感的能力, 即正面的情感状态 (Sentiment State)。回答中积极正面的情感能有效抑制抱怨行为中的负面情绪, 一方面是因为其回答带有一定的安抚, 如礼貌、幽默等能有效缓解在线负面口碑发布和传播者的情绪; 另一方面带有如真诚、同情等积极正面情感的回答更易被用户接受。因此这种正面情感状态对负面情绪的抑制会有效提高处理在线负面口碑的成功率<sup>[23]</sup>。

社区平台中用户表达情绪的主要方式是文本, 本文通过使用情感词典计算用户文档的平均情感得分, 以此表示用户的情感状态。情感得分的计算以情感极性 (Sentiment Polarity) 和情感强度 (Sentiment Intensity) 为基础, 本文使用知网的中文情感词典 HowNet 作为参考分析文档中的情感极性和情感强度, 具体包括正面和负面情感词语词典、正面和负面评价词语词典和程度级别词语词典。其中, 正面和负面词典是情感极性分析的基础; 程度级别词语虽没有情感倾向, 但会影响文本的情感强度。其中否定词词典未被 HowNet 收纳且本身没有情感倾向, 但否定词会改变情感极性的方向, 故本文在 HowNet 的基础上扩充了否定词词典。扩充后的情感词典如表 2.1 所示。

表 2.1 情感词典

词性描述	词汇实例	权值	个数
正面情感词语	爱、乐于、巴不得、叹为观止、……	1	836
负面情感词语	哀、不爽、不待见、不是滋味、……	-1	1254
正面评价词语	棒、便利、不可缺、别具匠心、……	1	3730
负面评价词语	暗、昂贵、不成熟、爱理不理、……	-1	3116
程度级别词语(最)	最、十足、倍加、绝对、充分、……	9	69
程度级别词语(很)	好、不少、分外、出奇、格外、……	7	42
程度级别词语(较)	多、更加、还要、较为、那么、……	5	37
程度级别词语(稍)	怪、稍稍、略微、有些、有点、……	3	29
程度级别词语(欠)	微、相对、不大、半点、轻度、……	1	12
否定词词语	不、没、别、不够、没有、……	-1	19

此情感词典将正面和负面词语分为正面情感词语、负面情感词语、正面评价词语和负面评价词语,并将其作为情感极性词语,其极性分别记为 1、-1、1 和 -1;将词语的程度级别分为 5 级,并将其作为情感强度词语,其权值用 1、3、5、7、9 表示,从 1 至 9 情感强度逐渐增强;否定词的权值用 -1 表示,并将其和程度级别词语一同作为情感强度词语对情感极性词语进行修饰。

本文在计算用户文档的情感极性  $SP$  和情感强度  $SI$  时,对文档  $d_i$  进行分句分词处理,将所得词与情感词典中的词进行匹配,获取文档语句内的情感极性词语和情感强度词语。通过计算文档内词语情感极性与情感强度乘积之和得出文档的平均情感得分,即本文所定义的情感状态  $SS$ ,表示为:

$$SS_i = \frac{\sum_{j=1}^N SP_{d_i,j} SI_{d_i,j}}{N} \quad (2.3)$$

其中  $SP_{d_i,j}$  表示文档  $d_i$  中第  $j$  个词的情感极性,  $SI_{d_i,j}$  表示文档  $d_i$  中第  $j$  个词的情感强度,  $N$  表示文档  $d_i$  中的情感词数,  $j = (1, 2, \dots, N)$ 。

### 2.2.3 互动程度

在面向在线负面口碑处理的专家识别中,用户的领域知识水平和情感状态是衡量其是否具有专家能力的直接因素。然而,在社会化媒体平台多方参与的前提下,用户的

专家能力能否有效体现与其领域知识水平和情感状态的传递广度和深度即互动程度 (Social Degree) 显著相关。广泛且深入的互动能有效提升专家用户的影响范围,对在线负面口碑的传播具有抑制作用。因此专家用户应当具有一定的互动程度以充分体现自身的专家能力。关注与被关注数常用来说明用户的互动程度,这种特征选取在说明社会化媒体用户社交程度时具有较好的效果<sup>[24]</sup>。高关注与被关注数对用户互动程度有很大的提升,但在专家识别背景中,单纯通过关注与被关注关系很难证明用户对其专家能力的认同。在处理在线负面口碑的过程中,用户首先会根据自己的情景发布抱怨,专家用户针对此问题提出解决方案即回答,回答被用户采纳则表明用户对回答者专家能力的认可,此时专家用户通过知识和情感的传递即互动满足了在线负面口碑发布者的需求;具有和提问者相同经历或看法的其他用户在对抱怨进行搜索和传播时也可以对回答进行标记,若标记为有用,则表示专家用户通过互动满足了在线负面口碑传播者的需求。作为社会化媒体平台,平台常对被采纳或标记有用数较高的回答赋予标签(如“推荐回答”、“精华”等),并根据被采纳或标记有用回答数计算用户累计推荐等级。同时,平台为调动用户互动的积极性,常根据用户的在线时长、发帖和回答数等计算用户等级。因此本文选取用户回答数、累计推荐等级和等级作为用户互动程度的指标综合反映用户领域知识水平和情感状态的传递深度和广度。基于以上分析,本文选择领域知识水平  $DKL$ 、情感状态  $SS$  和互动程度  $SD$  三种特征表示在线负面口碑处理的专家能力,如表 2.2 所示。

表 2.2 在线负面口碑处理的专家能力特征

特征	指标	描述
领域知识水平	知识文档相似度	用户知识文档与领域知识文档的相似度
情感状态	平均情感得分	用户所有文档的情感得分之和与情感词数的商
互动程度	回答数	用户的回答总数
	累计推荐等级	平台根据用户被标记推荐回答数计算的等级
	等级	平台根据用户积极性计算的等级

根据上文的专家能力描述,可将在线负面口碑处理的专家识别转化为一个二分类问题,并训练一个有监督的高斯核支持向量机 (Support Vector Machine) 分类器进行分类。分类器通过学习专家能力特征,以判定用户是否具有专家能力,从而完成专家用户的识别。

## 2.3 实验与分析

### 2.3.1 数据收集与预处理

为测试在线负面口碑处理专家识别的准确性,本文从中关村在线进行数据采集。该平台是中国专业的 IT 与数码门户网站,用户可在该平台发布抱怨问题、提出解决方案、搜索和浏览其他用户沉淀的历史内容。平台会根据用户的活跃程度计算等级,并根据用户参与问答的情况赋予用户专家称号,这些专家用户均经过平台审核,可信度较高,是进行专家识别实验的理想数据。

数据收集过程如下:从中关村在线网站分类栏目中“手机”领域的所有 11940 位用户作为数据源进行数据爬取。爬取内容主要包括用户手机领域回答历史、提问与回答数量、累计回答等级、累计推荐等级和平台个人等级。因本文主要研究在线负面口碑处理的专家识别,重点关注专家用户,故在此删除提问数量数据,并去除其中未发表或标记提问与回答数据的用户 10771 位,保留关注用户 1169 位。其中,因网页格式差异等原因导致部分用户数据爬取不完整,删除 28 位数据缺失用户后,保留有效用户 1141 位。

数据预处理过程如下:由于本文模型与算法均在文本数据的前提下进行设计,因此实验将用户回答历史中图片、视觉符号等非文本数据剔除。回答文本中同时存在较多的散列标签,它们作为句子的一部分存在,而又仅作为引用标签,故本文从历史回答文本中通过正则表达式去除了无意义的散列标签。为实现多样化的表达,用户可以使用重复符号和表情符号来表达特定情绪,由于本文基于情感词典分析用户情感,这些符号并未被词典收录,故在此去除重复符号和表情符号。此外,为保护用户隐私,实验通过哈希变换对用户 ID 进行了加密处理。

在完成了必要的数据收集和预处理后,本文从 11940 位用户中获取到 1169 位关注用户,其中 28 位用户缺失部分数据,故最终保留 1141 位有效用户数据作为实验样本数据。部分用户数据示例如表 3 所示。

为避免量纲不同对模型的影响,对所有指标数据进行归一化处理,具体为:

$$f_i = \frac{f'_i - f_{\min}}{f_{\max} - f_{\min}} \quad (2.4)$$

其中  $f_i$  表示指标的测量值  $f'_i$  归一化后的对应值,  $f_{\min}$  表示所有样本在此指标测量真实值中的最小值,  $f_{\max}$  表示所有样本在此指标测量真实值中的最大值。

实验从归一化后的 1141 个样本用户数据中随机抽取 80% 共 913 位用户作为训练集

表 2.3 用户数据示例

用户 ID	知识文档相似度	平均情感得分	回答数	累计推荐等级	等级
29637408	0.03863	3.49927	12	1	1
29792448	0.26281	7.40783	1529	3	34
29452432	0.02664	4.71405	157	1	23
29797317	0.44034	5.96295	719	4	12
29797439	0.44079	6.29400	1247	3	25

对支持向量机进行训练,训练通过松弛变量和惩罚参数调整分类超平面,以实现分类收敛。将剩下的 20% 共 228 位用户作为测试集,评估模型效果。

### 2.3.2 实验设计与分析

实验将在线负面口碑处理的专家识别问题转化为分类问题,并选用 SKlearn-SVM 包完成分类任务。在专家识别实验之前,先构建用于分析用户回答记录文档的词库,并基于该词库进行知识水平的计算。为提高对用户文档分词的准确率,利用现有词库(包括手机词汇大全、通讯与数码产品词汇等),加入网络流行语、口语方言等词语,构成新的分词词库,基于该词库对用户文档进行分词,计算用户的领域知识水平;利用扩充后的情感词典计算用户情感状态;利用爬取的数据计算用户互动程度。

在专家识别实验中,以领域知识水平、情感状态和互动程度这三类特征的 7 种不同组合  $C_{DKL\&SS\&SD}$ 、 $C_{DKL}$ 、 $C_{SS}$ 、 $C_{SD}$ 、 $C_{DKL\&SS}$ 、 $C_{DKL\&SD}$  和  $C_{SS\&SD}$  建立支持向量机分类模型实现专家识别,通过结果分析选取效果最好的组合。

关于评价指标,实验采用标准机器学习分类评价指标(准确率、精确率、召回率和  $F_1$  值)对专家识别效果进行评价。根据上述实验设计和评价指标设定,在线负面口碑专家识别的结果如表 2.4、图 2-1 所示。

由表 2.4 和图 2-1 可知,在线负面口碑处理的专家识别实验中综合考虑用户知识水平、情感状态和互动程度的分类模型  $C_{DKL\&SS\&SD}$  效果最佳(其中准确率为 88.05%,精确率为 88.92%,召回率为 95.57% 和  $F_1$  值为 92.13%,准确率和  $F_1$  值皆明显大于其他模型),这说明模型  $C_{DKL\&SS\&SD}$  在专家识别中具有明显优势。在单类特征模型中, $C_{SD}$  和  $C_{SS}$  的效果均优于  $C_{DKL}$ ,其中  $C_{SD}$  与  $C_{SS}$  的差别并不显著,这说明专家用户相对普通用户拥有更正面的情感状态和更高的互动程度。在两类特征模型中, $C_{DKL\&SS}$  的效果较优, $C_{SS\&SD}$  次之, $C_{DKL\&SD}$  较劣,但三者与  $C_{DKL}$  和  $C_{SS}$  之间差距亦不显著,且皆优于

表 2.4 专家识别实验结果

模型	$C_{DKL\&SS\&SD}$	$C_{DKL}$	$C_{SS}$	$C_{SD}$	$C_{DKL\&SS}$	$C_{DKL\&SD}$	$C_{SS\&SD}$
准确率	0.8805	0.7622	0.8054	0.8125	0.8595	0.8135	0.8270
精确率	0.8892	0.9533	0.9380	0.9062	0.8935	0.9677	0.9007
召回率	0.9557	0.5514	0.6541	0.7632	0.8162	0.6486	0.7351
$F_1$	0.9213	0.6987	0.7707	0.8286	0.8531	0.7767	0.8095




图 2-1 模型准确率与  $F_1$  值折线图

$C_{DKL}$ , 这说明本文定义的情感状态和互动程度相较领域知识水平更有助于在线负面口碑处理的专家识别, 尽管领域知识水平也可用于专家识别, 但其显著性低于综合特征分类模型和其他特征分类模型。

综上所述, 本文实验有如下发现: (1) 情感状态和互动程度相比领域知识水平更有助于进行在线负面口碑处理的专家识别; (2) 单独的领域知识水平特征不能很好的进行在线负面口碑处理的专家识别, 考虑领域知识水平、情感状态和互动程度三者混合的特征分类模型可以显著提高专家识别的准确率和总体效果。

## 2.4 结语

本文提出了一种基于支持向量机的在线负面口碑处理专家识别方法, 该方法将专家能力表述为领域知识水平、情感状态和互动程度三个特征维度, 以此构建支持向量机分类模型, 实现专家识别。实验表明综合考虑用户领域知识水平、情感状态和互动程度三维

的混合特征分类模型能更好的识别在线负面口碑处理的专家用户。在接下来的研究中,将增加实验数据的多样性,以提高该方法的泛化能力;此外,方法中用户领域知识水平和情感状态的计算均基于文本分析,错误的文本分析会直接影响识别的准确性,故研究提高文本分析的效果也是未来的工作之一。



## 参考文献

- [1] Coussement K, Poel D. Improving customer complaint management by automatic email classification using linguistic style features as predictors. *Decision Support Systems*, 2008, 44(4):870–882.
- [2] Jin J, Ji P, Kwong C. What makes consumers unsatisfied with your products: Review analysis at a fine-grained level. *Engineering Applications of Artificial Intelligence*, 2016, 47:38–48.
- [3] Hu M, Liu B. Mining opinion features in customer reviews. *AAAI*, volume 4, 2004. 755–760.
- [4] Moghaddam S, Ester M. Aspect-based opinion mining from product reviews. *Proceedings of the 35th international ACM SIGIR conference on Research and development in information retrieval*. ACM, 2012. 1184–1184.
- [5] Solovyev V, Ivanov V. Dictionary-based problem phrase extraction from user reviews. *International Conference on Text, Speech, and Dialogue*. Springer, 2014. 225–232.
- [6] Gupta N K. Extracting descriptions of problems with product and services from twitter data. *Proceedings of the 3rd Workshop on Social Web Search and Mining (SWSM2011)*. Beijing, China, 2011.
- [7] Ivanov V, Tutubalina E. Clause-based approach to extracting problem phrases from user reviews of products. *International Conference on Analysis of Images, Social Networks and Texts*. Springer, 2014. 229–236.
- [8] Kurihara K, Shimada K. Trouble information extraction based on a bootstrap approach from twitter. *PACLIC*, 2015.
- [9] De Saeger S, Torisawa K, Kazama J. Looking for trouble. *Proceedings of the 22nd International Conference on Computational Linguistics-Volume 1*. Association for Computational Linguistics, 2008. 185–192.
- [10] Tutubalina E. Target-based topic model for problem phrase extraction. *European Conference on Information Retrieval*. Springer, 2015. 271–277.
- [11] Tutubalina E. Dependency-based problem phrase extraction from user reviews of products. *International Conference on Text, Speech, and Dialogue*. Springer, 2015. 199–206.
- [12] Liu B, Hu M, Cheng J. Opinion observer: analyzing and comparing opinions on the web. *Proceedings of the 14th international conference on World Wide Web*. ACM, 2005. 342–351.
- [13] Lee A J, Yang F C, Chen C H, et al. Mining perceptual maps from consumer reviews. *Decision Support Systems*, 2016, 82:12–25.
- [14] Cortes C, Vapnik V. Support-vector networks. *Machine learning*, 1995, 20(3):273–297.
- [15] Victor D, Stevens M. United airlines passenger violently dragged from seat on overbooked flight, 2017.
- [16] Fornell C, Wernerfelt B. Defensive marketing strategy by customer complaint management: a theoretical analysis. *Journal of Marketing research*, 1987. 337–346.
- [17] Woong Yun G, Park S Y. Selective posting: Willingness to post a message online. *Journal of Computer-Mediated Communication*, 2011, 16(2):201–227.

- [18] Dellarocas C. Strategic manipulation of internet opinion forums: Implications for consumers and firms. *Management science*, 2006, 52(10):1577–1593.
- [19] Van Noort G, Willemsen L M. Online damage control: The effects of proactive versus reactive webcare interventions in consumer-generated and brand-generated platforms. *Journal of Interactive Marketing*, 2012, 26(3):131–140.
- [20] Noble C H, Noble S M, Adjei M T. Let them talk! managing primary and extended online brand communities for success. *Business horizons*, 2012, 55(5):475–483.
- [21] 蔡淑琴, 秦志勇, 蒋士森, et al. 基于回归树与衰减函数的在线负面口碑影响力预测. *系统工程理论与实践*, 2016, 36(6):1496–1504.
- [22] Cheng X, Zhu S, Chen G, et al. Exploiting user feedback for expert finding in community question answering. *Data Mining Workshop (ICDMW)*, 2015 IEEE International Conference on. IEEE, 2015. 295–302.
- [23] Kim S, Oh J S, Oh S. Best-answer selection criteria in a social q&a site from the user-oriented relevance perspective. *Proceedings of the Association for Information Science and Technology*, 2007, 44(1):1–15.
- [24] Cha M, Haddadi H, Benevenuto F, et al. Measuring user influence in twitter: The million follower fallacy. *Icwsn*, 2010, 10(10-17):30.

## 个人简历